

Базови модели и данни за предварително обучение

Лекция 6

Част 2: Как се обучават базови модели

Transfer learning, BERT и обучителни задачи

Преди 2018: всяка задача — от нулата

За всяка задача от обработката на естествен език (NLP) — **отделна архитектура**, обучена от нулата:

- Анализ на настроения (sentiment analysis) → специфичен модел
- Разпознаване на именувани обекти (NER) → друг модел
- Машинен превод → трети модел

Word2Vec, GloVe — пренос на ниво *думи*, но не на ниво *контекст*.

ELMo (Peters et al., 2018) — първи стъпки: контекстуални вграждания (embeddings) от двупосочна LSTM. Но все още: отделен модел за всяка задача, с ELMo вграждания като вход.

BERT: предварително обучение → фина настройка

Ключова идея: обучи *един* голям модел на огромен корпус, после го адаптирай.

Етап	Какво	Данни	Време
Предварително обучение	MLM + Next Sentence Prediction	BookCorpus + Wikipedia (3.3B думи)	Дни на TPU
Фина настройка	Добави един слой, обучи	Малък етикетиран набор от данни	Минути на GPU

Резултат: SOTA на 11 NLP benchmark-а едновременно.


Мащабът на BERT: сравнение с nanoGPT

В Лекция 5 обучихме nanoGPT на Вазов. Колко по-голям е BERT?

	nanoGPT (L5)	BERT-base	BERT-large
Параметри	~10K	110M	340M
Слоеве	1–2	12	24
Размерност (d_model)	64	768	1024
Глави на вниманието	1–2	12	16
Обучаващи данни	~500K токена (Вазов)	3.3B думи (Wikipedia + BookCorpus)	
Обучение	Секунди на лаптоп	Дни на 16 TPU	

×11,000 повече параметри. ×6,000 повече данни. И това беше 2018 — "малък" модел по днешните стандарти.

Transfer learning: защо работи



Предварително обученият модел е научил езикова структура — синтаксис, семантика, световно знание.

Фината настройка пренасочва тези знания към конкретна задача.

Аналогия: човек, който знае български, учи нова тема — не учи езика отначало.

Затова **данните за предварително обучение** са толкова важни (Част 3).

BERT: задачи надолу по веригата (downstream tasks)

Един предварително обучен модел → фина настройка за различни задачи:

Задача	Набор от данни	Какво прави
Анализ на настроения	SST-2	Положителна / отрицателна рецензия на филм
Извод от естествен език (NLI)	MNLI	Дадени две изречения: следствие, противоречие или неутрално?
Отговор на въпроси	SQuAD	Маркира отговора в даден параграф

Всички тези задачи — с един и същ BERT модел + различен финален слой.

Benchmark **GLUE** (General Language Understanding Evaluation) обединява 9 такива задачи. BERT постигна SOTA на всичките едновременно — затова го нарекоха "**ImageNet момент**" за NLP.

BERT днес: съвременни варианти

Подобрения на оригинала:

- **RoBERTa** (2019) — повече данни, по-дълго обучение, без NSP → стана стандартна основа
- **DeBERTa** (2020) — подобро внимание с разделени позиции → дълго време #1 на GLUE
- **ModernBERT** (2024) — актуализирана архитектура с RoPE, GeLU, Flash Attention, 8192 токена контекст

За семантично търсене и вграждания:

- **Sentence-BERT (SBERT)** — обучен за сравняване на цели изречения по косинусова близост
- **BGE, E5, GTE** — съвременни модели за вграждания, базирани на BERT архитектурата
- Използват се масово за RAG, семантично търсене, класификация (Лекция 11)

BERT не изчезна — напротив, за задачи, които не изискват генериране, енкодер моделите остават по-бързи и по-ефективни от големите езикови модели.

От BERT към GPT линията

Но **GPT линията** тръгна в друга посока: само декодер, мащабиране вместо фина настройка.

Подход	Философия
BERT линия	По-малък модел + фина настройка за конкретна задача
GPT линия	По-голям модел + обучение с инструкции → един модел за всичко

Двата подхода съжителстват и днес — изборът зависи от задачата, бюджета и латентността.

Обучителни задачи: MLM vs NTP

Маскирано езиково моделиране (MLM, BERT):

Маскираме 15% от токените → предвиждаме маскираните.

Вход: Столицата на [MASK] е [MASK].
Цел: Столицата на България е София.

Предвиждане на следващ токен (NTP, GPT/LLaMA):

Предвиждаме следващия токен — каузално, отляво надясно.

Вход: Столицата на България е
Цел: София

Познато от L1 (n-грами) → L5 (nanoGPT) → днес (LLaMA): все **NTP**.

MLM vs NTP: сравнение

Аспект	MLM (BERT)	NTP (GPT/LLaMA)
Контекст	Двупосочен (bidirectional)	Каузален (ляво → дясно)
Генериране	Не	Да
Пренос на знания	Фина настройка	Фина настройка или in-context (при мащаб)
Доминира	2018–2020	2020–днес

Защо NTP спечели: по-просто, мащабира се, настройката с инструкции (instruction tuning) го прави универсален.

BERT не изчезна — все още е навсякъде за вграждания и класификация.

Преход: нека видим и двата подхода на практика → тетрадка

Част 3: Данните за обучение

Откъде идват и как ги подготвяме

Откъде идват данните

Common Crawl — най-големият публичен уеб корпус: стотици милиарди страници. Сурова снимка на интернета.

Производни:

- **C4** (статия за T5) — филтриран Common Crawl
- **RefinedWeb** (Falcon) — по-стриктна обработка
- **FineWeb** (HuggingFace) — най-скорошен, открит процес

Специализирани източници:

- Книги: BookCorpus, Books3
- Код: GitHub, The Stack — *код помага на разсъждението*
- Научен текст: arXiv, PubMed
- Wikipedia, StackExchange

LLaMA: конкретни числа

Източник	Дял	Епохи
CommonCrawl (CCNet)	67.0%	1.0
C4	15.0%	1.0
GitHub	4.5%	0.64
Wikipedia	4.5%	2.45
Books	4.5%	2.23
ArXiv	2.5%	1.06
StackExchange	2.0%	1.03

1.4T токена — само публични данни.

Теглата при семплиране $\neq$ размер на набора от данни: Wikipedia и Books се виждат **повече пъти**.

Мащабът на LLaMA: от nanoGPT до съвременен ГЕМ

	nanoGPT (L5)	BERT (2018)	GPT-2 (2019)	LLaMA 1 (2023)	LLaMA 3 (2024)
Параметри	~10K	110M	1.5B	7B – 65B	8B – 405B
Данни (токени)	~500K	~4B	~10B	1.4T	15T+
Контекст	64	512	1024	2048	128K

Скокът:

- От nanoGPT до BERT: **×11,000** параметри
- От BERT до LLaMA 65B: **×590** параметри
- От nanoGPT до LLaMA 65B: **×6,500,000** параметри

Кратко за **българския**: малък дял в обучаващите данни → по-слабо представяне на LLaMA на български.


Законите за мащабиране (scaling laws) формализират тази зависимост — Лекция 7.

Как данните влияят на модела

- Повече **код** в обучението → по-добро **разсъждение** (наблюдение от LLaMA и CodeLLaMA)
- По-качествени данни при фиксиран бюджет > повече мръсни данни
- Съставът на обучаващите данни директно определя какво "знае" моделът

"Garbage in, garbage out" — това ни води към качеството...

Филтриране: от сурово обхождане до качествени данни



- Всяка стъпка **намалява обема** — остават само няколко % от суровото обхождане
- **Качество > количество** при фиксиран изчислителен бюджет
- Съставът на данните директно определя какво "знае" моделът

Филтриране: конкретни стъпки

Езикова идентификация

- fastText класификатор — определя езика на документа
- Отхвърля документи под праг на увереност

Евристични правила

- Твърде кратък текст, повторения на едно и също изречение
- Шаблонен текст (навигация, cookie банери), специални символи

Качествен класификатор (LLaMA подход)

- Обучен да разпознава текст, подобен на Wikipedia
- Подрежда документите по "качество"

Допълнително: премахване на токсично съдържание, лична информация (PII), списък с блокирани домейни.

Дедупликация: защо е важна

Дублиран текст → запаметяване вместо генерализация (Lee et al. 2022).

Моделът буквално **запомня** повтарящи се пасажки, вместо да учи от тях.

Точна дедупликация — хеш на целия документ.

- Просто и бързо
- Но малка промяна (интервал, дата) го заобикаля

Приблизителна дедупликация — MinHash + LSH.

- Документ → множество от n -грами → MinHash сигнатури → LSH за групиране
- Апроксимира сходството по Jaccard без $O(n^2)$ сравнения
- LLaMA: 5-gram MinHash, праг на Jaccard 0.8

Сходство по Jaccard

Мярка за сходство между две множества:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

- $J = 1 \rightarrow$ идентични множества
- $J = 0 \rightarrow$ нищо общо
- $J > 0.8 \rightarrow$ "достатъчно сходни" $\rightarrow$ вероятни дубликати

Проблем: сравняването на всяка двойка документи е $O(n^2)$ — непрактично за милиарди документи.

Решение: MinHash — апроксимира Jaccard чрез хеширане.

Нека видим как работи MinHash на практика $\rightarrow$ тетрадка

Замърсяване (contamination) и обобщение

Когато обучаващите данни съдържат тестовите

Замърсяване на данните: скрит проблем

Обучаващите данни могат да съдържат **benchmark тестове** (MMLU, GSM8K, HumanEval).

Ако моделът е "виждал" тестовите въпроси — **резултатите не са валидни**.

Методи за откриване:

Метод	Как работи
N-gram припокриване	Търси дълги съвпадения между обучаващи данни и тестове
Перплексия	Подозрително ниска перплексия на тестови примери
Canary strings	Вмъкват се уникални низове в benchmark-а и се проверява дали моделът ги "знае"

Статията за LLaMA: анализ на замърсяването с n-gram припокриване за всеки benchmark.

Замърсяване: отворен проблем

При затворени модели (GPT-4, Claude, Gemini):

- Нямаме достъп до обучаващите данни
- Не можем да проверим за замърсяване
- Трябва да се доверим на авторите

При отворени модели (LLaMA, Mistral):

- Обучаващите данни (понякога) са публични
- Можем да направим собствен анализ
- Но огромният обем прави проверката трудна

Нови benchmarks бързо се "замърсяват" — появяват се в уеб страници, които влизат в следващото обхождане.

Обобщение: BERT vs LLaMA

	BERT (2018)	LLaMA (2023)
Архитектура	Само енкодер	Само декодер
Обучителна задача	MLM	NTP
Нормализация	LayerNorm (post)	RMSNorm (pre)
Активационна функция	GELU	SwiGLU
Позиционно кодиране	Научени	RoPE
Данни	3.3B думи	1.4T токена
Пренос на знания	Фина настройка	Фина настройка или in-context
Параметри	110M / 340M	7B – 65B

Процес: събиране → филтриране → дедупликация → проверка за замърсяване → обучение.

Ключови изводи

1. **Transfer learning** промени NLP: предварително обучение веднъж → фина настройка многократно
2. **Предвиждане на следващ токен доминира** — по-просто, мащабира се, генерира текст
3. **Данните са толкова важни колкото архитектурата** — може би повече
4. **Качество > количество** при фиксиран изчислителен бюджет
5. **Дедупликация и филтриране** са критични — без тях моделът запаметява вместо да генерализира

Тийзър за Лекция 7

BERT: 110M → GPT-2: 1.5B → LLaMA: 65B — какво се случва при мащабиране?

- **Закони за мащабиране** (scaling laws) формализират връзката параметри $\leftrightarrow$ данни $\leftrightarrow$ compute
- **Статията за GPT-2:** задачи без примери (zero-shot) без фина настройка — първи знаци за нововъзникващи способности
- Повече $\neq$ просто по-добро. Повече = **различно**.

Следващата лекция: защо повече = различно, не просто по-добро.

Дискусия

- Защо предвиждането на следващ токен е достатъчно да обучи модел, който "разбира" език?
- BERT доминираше 2 години — какво се промени?
- Ако данните определят поведението — кой решава какви данни влизат?
- Данните на интернета растат с текст, генериран от големи езикови модели — какво следва?

Ресурси

- Devlin et al. 2018 — *BERT: Pre-training of Deep Bidirectional Transformers*
- Touvron et al. 2023 — *LLaMA: Open and Efficient Foundation Language Models*
- Peters et al. 2018 — *Deep contextualized word representations* (ELMo)
- Lee et al. 2022 — *Deduplicating Training Data Makes Language Models Better*
- Penedo et al. 2024 — *The FineWeb Datasets*
- Broder 1997 — *On the Resemblance and Containment of Documents* (MinHash)