

Обучение с подсилване

Въведение преди RLHF

Три начина да учиш машина

Трите парадигми на машинното самообучение

Парадигма	Какво даваме	Какво учи машината
Обучение с учител	(вход, верен изход)	Да имитира правилни отговори
Обучение без учител	само входове	Да открива структура сама
Обучение с подсилване	само обратна връзка (награда)	Да взима добри решения

Обучението с подсилване е различно: **не показваме верния отговор.**


Казваме само дали резултатът е бил добър или лош — и оставяме агента да се оправи сам.

Какво може да се научи така?


Примери: какво е постигнало обучението с подсилване

- **Го и шах** — AlphaZero победи световните шампиони, играейки само срещу себе си
- **Видеоигри Atari** — само пиксели на входа, само оценката на изхода — без правила
- **Ходене на роботи** — от пълно падане до стабилен ход, само чрез проба и грешка
- **Акробатика с дронове** — пилотаж, невъзможен за хора, научен от нулата
- **Управление на охлаждане** — DeepMind намали разхода за охлаждане на Google с 40%
- **Езикови модели** — за това е цялата лекция

REAL WORLD APPLICATIONS OF REINFORCEMENT LEARNING



AI in Games



Robotic Control



Smart Energy



Personalized Recommendations

Основният цикъл

Агент и среда



Всичко в обучението с подсилване се свежда до тази схема:

1. Агентът **наблюдава** текущото състояние на средата
2. Взима **действие**
3. Средата се **сменя** — новото състояние + награда се връщат на агента
4. Цикълът се повтаря

Обучението се свежда до едно: тази стъпка, повторена милиони пъти.

Ключовите понятия

Агент и среда

Агентът е субектът, който взима решения.

Средата е всичко останало — светът, с който агентът взаимодейства.

Граница между двете:

Агентът решава. Средата реагира.

- В Го: агентът е програмата, средата е дъската и противникът
- При работа: агентът е контролерът, средата е физическият свят
- При езиков модел: агентът е моделът, средата е разговорът (и хората в него)

Състояние

Състоянието (s) е снимката на света в даден момент — всичко, което агентът вижда.

Примери:

- При Atari: **пикселите на екрана** в момента
- При робота: **позицията и ъгловата скорост** на всяка става
- При шах: **наредбата на фигурите** на дъската
- При езиков модел: **целият разговор досега**

Агентът не вижда бъдещето — само текущото състояние.

Задачата е да вземе добро решение само от него.

Действие

Действието (а) е изборът, който агентът взима в дадено състояние.

Примери:

- При Atari: ляво, дясно, скочи, стреляй (краен набор)
- При робота: въртящ момент върху всяка става (непрекъснат диапазон)
- При шах: кой ход да направи (до ~30 опции)
- При езиков модел: **кой токен да генерира следващ** (50 000 опции)

Действията могат да са прости или сложни — но на всяка стъпка агентът избира едно.

Награда

Наградата (r) е скалар — едно число, което казва дали последното действие е било добро.

Примери:

- Atari: +1 за всеки унищожен блок, -1 при смърт
- Шах: +1 при победа, -1 при загуба, 0 иначе
- Робот, който ходи: +0.1 за всеки изминат сантиметър напред
- Езиков модел: **оценка от хората** (или от модел на наградата)

Наградата не обяснява *какво* да направиш — само *дали* е сработило. Агентът сам трябва да открие какво е довело до нея.

Политика — сърцето на обучението с подсилване

Политиката (π) е стратегията на агента: при всяко възможно състояние — какво да прави.

Можете да мислите за нея почти като за самия агент.

Ако знаете политиката на даден агент — знаете всичко за поведението му.

Политиката е агентът, в смисъла, който има значение.

Формално: $\pi(s) \rightarrow a$ — функция от състояние към действие.

На практика (при невронни мрежи): политиката е **разпределение на вероятностите** над действия.

При езиков модел: вероятността за всеки следващ токен — точно `softmax` изходът.

Целта на обучението с подсилване е да намерим най-добрата политика.

Епизод и разредена награда

Епизодът е пълна последователност от действия — от начало до край.

При шах: от първия ход до мат или ремис.

Разредена награда (sparse reward): наградата идва само в края.

При шах никой не ти казва дали ход 12 е бил добър. Разбираш едва след мат — 40 хода по-късно.

Това е проблемът с приписването на заслугата (**credit assignment**):

Кое от 40-те действия е довело до победата?

Колкото по-дълъг е епизодът и по-разредена наградата — толкова по-трудно е обучението.

Изследване срещу експлоатация

Дилемата: изследване или използване?

Агентът научава нещо, което работи. Трябва ли винаги да го прави?

Само експлоатация (exploitation): прави винаги това, което досега е носило награда.

→ Никога не открива нещо по-добро. Заклежда се в локален оптимум.

Само изследване (exploration): пробва случайни неща, за да открие нещо ново.

→ Никога не използва наученото. Никога не стига до висока награда.

Нужен е баланс — и правилният баланс зависи от задачата.

Представете си ресторант. Ако винаги поръчвате едно и също — не откривате по-добрите ястия.

Ако всеки път поръчвате нещо ново — никога не ядете любимото си.

Алгоритми

Три подхода за учене на политика

Базиран на стойност (Value-based)

Учим колко добро е всяко (s, a) — *"ако направя това тук, колко награда ще спечеля общо?"*

Политиката следва автоматично: избирай действието с най-висока очаквана стойност.

Пример: Q-learning, DQN (Atari от DeepMind).

Базиран на политика (Policy-based / Policy Gradients)

Директно оптимизираме политиката. Ако дадено действие е довело до награда — увеличаваме вероятността му.

По-директно, но по-шумно.

Actor-Critic

Комбинира двете: актьорът е политиката (взима решения), критикът е стойностната функция (оценява ги).

PPO — алгоритъмът в RLHF — е от този тип. ✓

AlphaZero

Обучение от нулата


AlphaZero — само правилата, нищо повече

DeepMind, 2017. Шах, Го, шогі — три игри, три световни шампиона победени.

Без човешки партии. Без стратегии от учебници.
Само правилата на играта.

Три ключови идеи:

1. **Игра срещу себе си (Self-play)** — агентът играе срещу предишна версия на себе си. Противникът расте заедно с него.
2. **Планиране с MCTS** — преди всеки ход симулира хиляди бъдещи варианти, за да прецени кой е най-обещаващ.
3. **Обща невронна мрежа** — една мрежа дава едновременно политика (кой ход?) и оценка на позицията (кой е по-добре?).



Защо AlphaZero е важен за нас

AlphaZero доказва нещо дълбоко:

RL може да постигне над-човешко представяне **без никакви демонстрации**.

Само от наградата — победа или загуба.

При RLHF нямаме тази чистота — не можем да проверим "добър отговор" като мат на дъска. Затова ни трябва *научен* модел на наградата вместо проверяем сигнал.

Но принципът е същият: **оптимизираме политика чрез взаимодействие**, не чрез имитация.

Защо RL е труден

Четири предизвикателства

1. Неефективност на извадките

Нужни са милиони епизоди за нещо, което човек научава за часове.

AlphaZero изигра ~44 милиона шахматни партии за 9 часа.

2. Манипулиране на наградата (Reward hacking)

Агентът открива начини да максимизира наградата, без да постигне реалната цел.

Класика: робот, обучен да бяга бързо, открива, че е по-лесно да расте висок и да пада напред.

3. Приписване на заслугата (Credit assignment)

При дълги епизоди — кое действие е довело до крайната награда?

4. Нестационарност

Средата се мени, щом политиката се мени — особено при игра срещу себе си.

Тези предизвикателства не изчезват при RLHF. Ще ги срещнем отново — под различни имена.

RL среща езиковите модели

Всичко е същото — само имената са различни

RL	RLHF
Агент	Езиков модел
Среда	Хората (или модел на наградата)
Състояние	Целият контекст на разговора досега
Действие	Следващият токен
Политика	Разпределението на вероятностите на модела
Награда	Оценка на предпочитанието от хора
Епизод	Един пълен отговор

Манипулирането на наградата → политиката генерира многословни, сервилни отговори.

Приписването на заслугата → кой токен е направил отговора добър?

Нестационарност → политиката се мени; RM е обучен на стари данни.

Всичко, което казахме, важи тук. Само имената са различни.