

Групов проект

Предложения и оценяване

24.04.2026

Общи правила

Екипи: 2–4 души. Всеки член отговаря за значима част от проекта и познава общата архитектура. Специализирани компоненти извън обхвата на курса ще се защитават от автора им.

Ключови срокове

- **05.06.2026** — предаване на екип, избрана тема и разпределение на задачите
- **Юнска сесия** — защита на проекта; точната дата се обявява в Мудъл

Какво се предава в края

- Работещ код в Git хранилище (README с инструкции за стартиране)
- Кратък документ или слайдове (структура — вж. "Срокове и предаване")
- Репродуцируем експеримент или демо за представяне на живо

Обхват: темите по-долу са примерни. За собствена идея — вж. "Срокове и предаване".

Оценяване

Оценката е **индивидуална**. Всеки член на екипа се изпитва върху проекта.

Критерий	Тегло
Качество и работоспособност на кода	30%
Дълбочина — разбиране на собствената част и обосновани решения	35%
Обяснение — ясно представяне на <i>какво</i> и <i>защо</i>	25%
Оценяване — метрики, сравнения, честни ограничения	10%

Бонус: Иновация — нестандартен ъгъл, нов набор от данни, собствен експеримент.

Очакване: всеки студент може да обясни архитектурата на проекта като цяло и своята част в дълбочина. Специализирани компоненти се защитават основно от автора им.

Пример 1 — Модернизация на spaCy фина настройка за български

Идея: spaCy има ограничено покритие за български. Модернизирайте обработката за фина настройка с актуален модел (напр. XLM-RoBERTa, multilingual BERT, български BERT) за конкретна задача — NER, POS тагване или класификация на текст. spaCy (<https://github.com/melaniab/spacy-pipeline-bg>) transformer (<https://spacy.io/api/transformer>)

Защо е интересно: реално приложимо; сравнявате класически NLP пайплайн срещу съвременен трансформатор върху *същия* български набор от данни.

Покрива от курса: L3 (токенизация), L4–L5 (трансформатор), L6 (трансфер на знания, фина настройка).

Възможно разделение (3–4 души)

- Подготовка на данните и анотации (преобразуване към spaCy формат, качество на етикетите)
- Тренировъчен цикъл и претърсване на хиперпараметри
- Оценяване — F1, precision/recall, сравнение с базов spaCy модел
- Интеграция — CLI или spaCy пайплайн компонент, инсталируем с `pip`

Пример 2 — Откриване на инжекция в подканата (prompt injection) чрез фина настройка

Идея: Фино настройте малък класификатор (напр. DistilBERT, MiniLM) върху набор от данни за prompt injection (например **FinGuard**, Deepset injection dataset, или собствен). Моделът казва: "това е опит за injection" или "чиста подкана".

Защо е интересно: това е тема от L8 (съгласуване, безопасност) — всеки, който интегрира голям езиков модел в продукт, се сблъсква с нея.

Покрива от курса: L3 (токенизация), L6 (SFT), L8 (съгласуване, red teaming).

Възможно разделение

- Подбор и почистване на данните — балансиране, допълване с adversarial примери
- Обучение — фина настройка на 2–3 различни backbone-a
- Adversarial тестване — red teaming, опит да се заобиколи детекторът
- Интеграция и сервиране (FastAPI / Ollama guardrail hook)

Пример 3 — RAG асистент за българско счетоводство и данъчно право

Идея: Асистент, който отговаря на въпроси от тип *"какви са осигуровките за СОЛ през 2026"* с **цитати от първоизточника** (ЗКПО, ЗДДС, ЗДДФЛ, КСО, указания на НАП).

Покрива от курса: L3 (токенизация за български), L6 (качество на данните), L11 (RAG, векторна база данни, извличане).

Стъпки: Сваляне (lex.bg, пар.bg) → Трансформация (разделяне по член/алинея) → Качване (вграждания във векторна база данни) → Извличане (хибридно търсене + преподреждане) → Генериране (с цитати, отказ при липса на източник).

Възможно разделение: по стъпките. Оценяване на отговорите от системата — обоснованост на отговора, точност на цитатите.

Пример 4 — Локален изследователски агент за arXiv (Ollama + ReAct)

Идея: Локален агент, който приема тема и връща **структуриран литературен обзор** — релевантни статии, резюмета, сравнителна таблица, отворени въпроси.

Покрива от курса: L9 (Ollama, квантизация), L10 (инженерство на подканите, мисловни вериги), L12 (ReAct, инструменти, памет).

Инструменти: `arxiv_search`, `fetch_pdf`, `summarize`, `compare`, `note / recall` (дългосрочна памет).

Възможно разделение: (1) инструменти + кеш, (2) цикъл на агента (ReAct + reflection), (3) памет и стратегия за резюмиране, (4) оценяване върху реални теми.

Пример 5 — Фина настройка на локален модел с LoRA

Идея: Фина настройка с **LoRA** на малък отворен модел (напр. Llama 3.2 1B, Qwen 2.5 0.5–1.5B) за конкретна задача — класификация, извличане на структурирана информация или генериране в определен стил.

Защо е интересно: достъпно като хардуерни изисквания; пряко сравнение на няколко подхода върху една и съща задача.

Покрива от курса: L6 (фина настройка, SFT), L9 (локални модели, квантизация), L10 (инженерство на подканите, few-shot).

Сравнителен експеримент: базов модел без настройка → инженерство на подканите с few-shot примери → LoRA фина настройка. Единен тестов набор и метрики.

Възможно разделение: (1) данни и тестов набор, (2) тренировка с LoRA и хиперпараметри, (3) базови подходи с подкани, (4) оценяване и сравнителен анализ.

Срокове и предаване

До 15.05.2026 — предложение за собствена тема по имейл. Възможно е обсъждане и лично след лекция.

05.06.2026 — предаване на екип, избрана тема и разпределение на задачите.

Юнска сесия — защита на проекта; точната дата се обявява в Мудъл. Защита преди обявената дата е възможна при готовност.

Как се предава: в Мудъл — линк към Git хранилище, заедно с членовете на екипа и темата. Възможно е и ZIP стига да има ясни стъпки за репродукция.

Препоръчителна структура на документа/слайдовете (свободен формат):

1. Задача и мотивация
2. Подход и архитектурни решения
3. Данни и експерименти
4. Резултати и сравнения
5. Ограничения и бъдеща работа

Защита на проекта

Формат: целият екип присъства; всеки член представя собствения си принос и отговаря на въпроси.

Време на студент: 15 минути представяне + 10 минути въпроси.

Какво очакваме в представянето

- Ясно формулирана задача и избрано решение
- Демонстрация на живо или репродуцируем експеримент
- Обосновка на ключови решения (*какво и защо*)
- Честно обсъждане на ограниченията и възможни подобрения

Обхват на въпросите: архитектурата на проекта като цяло и собствената част в дълбочина. Специализирани алгоритми извън материала се изпитват основно при автора им.