

Агенти с изкуствен интелект и инструменти

Лекция 13

Кратък преговор — Лекция 12


- Големите езикови модели (ГЕМ) могат да звучат уверено без проверим източник.
- RAG добавя **извличане**: документни части влизат в контекста преди отговора.
- Качеството зависи от разделяне на документи, векторни вграждания, извличане и цитиране.
- RAG намалява халюцинациите, но не прави системата автоматично изпълнител на задачи.

Днес: моделът вече не само получава контекст, а избира кога да търси, проверява, действа или пита човек.

Въпрос за дискусия

Какво може и какво *не може* да направи самостоятелно един ГЕМ?


Google Trends



План

1. Какво е агент с изкуствен интелект?
2. Основен модел на агентна система
3. Агентен цикъл и ReAct
4. Инструменти и извикване на функции
5. Контекст, състояние и памет на агента
6. Планиране и препланиране
7. Надеждност, оценяване и наблюдаемост
8. Безопасност, контрол и човек в цикъла

Езиков модел, чатбот, работен поток, агент



Какво е агент с изкуствен интелект?

Агент с изкуствен интелект е система, която:

- получава цел;
- наблюдава среда;
- избира действие;
- използва обратна връзка;
- продължава, докато стигне до успех, отказ или нужда от човек.

ГЕМ не е целият агент. ГЕМ обикновено е контролерът, който избира следващата стъпка.

Кога агентността е полезна?

Агентността помага, когато задачата:


- има няколко зависими стъпки;
- изисква външни данни или инструменти;
- може да се промени след ново наблюдение;
- има проверим критерий за успех;
- не може да се реши надеждно с един отговор.

Пример: „Организирай среща“ изисква календар, имейл, предпочитания, проверка и потвърждение.

↓ Тетрадка

Обикновена подкана срещу агент с инструмент

Основен модел на агентна система



Цел, среда, наблюдения и действия

Елемент	Какво означава
Цел	Какво трябва да бъде постигнато
Среда	Светът извън модела: файлове, календар, имейл, уеб, база данни
Наблюдение	Какво агентът вижда след действие или заявка
Действие	Позволена операция: търсене, четене, писане, изчисление, въпрос към човек

Агентът е ограничен от действията, които системата му позволява.

Големият езиков модел като контролер и пространство на действията

ГЕМ контролерът избира какво да се случи следващо:

- да отговори директно;
- да извика инструмент;
- да поиска още информация;
- да спре, защото целта е постигната;
- да спре, защото действието е рисково или невъзможно.


Пространството на действията е списъкът с позволени действия, параметри и ограничения.

Състояние, обратна връзка и критерий за успех

- **Състояние:** текуща информация, междинни резултати и история на стъпките.
- **Обратна връзка:** резултатът от действие, грешка, празен отговор или потвърждение от човек.
- **Критерий за успех:** конкретно условие, по което агентът знае, че задачата е завършена.

Без критерий за успех агентът лесно започва да „подобрява“ отговора без край.

Агентен цикъл: ReAct (разсъждение + действие)



Условия за спиране и контрол срещу безкрайни цикли

Агентът трябва да спира при ясни условия:

- целта е постигната;
- достигнат е лимит на стъпки, време или цена;
- инструмент връща непоправима грешка;
- резултатите започват да се повтарят;
- нужно е човешко решение.

↓ Тетрадка

Проследяване на агентен цикъл (ReAct)

Инструменти и извикване на функции

Инструмент е ограничена функция, която агентът може да извика със структурирани параметри.

Примери:

- `search_email(query, limit)`
- `read_calendar(date)`
- `create_event(title, start, end, attendees)`
- `calculate(expression)`

Инструментът прави нещо извън езиковия модел, а резултатът се връща като ново наблюдение.

Схема на инструмент

Схемата е договор между модела, оркестратора и реалната функция.

Част	Какво трябва да казва
Име	Стабилен идентификатор: <code>read_calendar</code>
Описание	Кога се използва инструментът и кога не
Параметри	Типове, задължителни полета, позволени стойности
Резултат	Структурата на наблюдението при успех
Грешки	Очаквани кодове, празни резултати и невалидни входове
Странични ефекти	Дали само чете, или променя външна система

Колкото по-ясна е схемата, толкова по-малко моделът трябва да гадае.

Model Context Protocol (MCP)

MCP е стандартен начин приложение с ГЕМ да се свързва с външни възможности.

Вместо всяка интеграция да е специален код, MCP сървър може да предоставя:

- **инструменти** — действия, които моделът може да поиска;
- **ресурси** — данни и контекст, които могат да се добавят към задачата;
- **подкани** — готови шаблони за чести работни потоци.

MCP помага за откриване и описване на възможности, но не отменя нуждата от валидация, права и човешко потвърждение при рискови действия.

Добри и лоши практики при инструментите

Добър инструмент	Лош инструмент
Ясна, малка задача	Твърде обща задача
Малко параметри	Неясни параметри
Предвидим резултат	Свободен текст без структура
Ограничени права	Прекомерен достъп
Ясни грешки	Мълчалив провал

Валидацията проверява типове, празни резултати, грешки и опасни странични ефекти.

От избор на инструмент до ново наблюдение



↓ Тетрадка

Избор, извикване и валидиране на инструмент

Контекстен прозорец, състояние и памет на агента

Контекстен прозорец	Работно състояние	Дългосрочна памет
Това, което моделът вижда в текущото извикване.	Бележки за текущата задача и междинни резултати.	Информация извън текущия разговор.
Системни инструкции, последни съобщения, извлечени данни, резултати от инструменти.	План, изпълнени стъпки, последни наблюдения, временни решения.	Файлове, резюмета, база данни, векторна база данни.
Ограничен е от токени и лесно се пълни с шум.	Трябва да е кратко, актуално и проверимо.	Трябва да се извлича селективно и да се проверява преди употреба.

План, изпълнение и препланиране

Агентът не трябва само да има план. Той трябва да го променя при нова информация.

1. **Планиране:** разбиване на целта на проверими стъпки.
2. **Изпълнение:** избор на действие за текущата стъпка.
3. **Проверка:** сравнение с наблюдение или критерий за успех.
4. **Препланиране:** промяна след грешка, липсващи данни или ново ограничение.

Фиксиран работен поток е по-добър, когато стъпките са напълно предвидими.

Чести провали на агентите

- Избира грешен инструмент.
- Подава грешни параметри.
- Приема празен или шумен резултат за доказателство.
- Измисля наблюдение вместо да изчака инструмент.
- Губи важен контекст след много стъпки.
- Продължава, въпреки че трябва да спре.
- Извършва действие с твърде големи права.

Повечето провали са системни, не само „лош отговор“ от модела.

Оценяване по задачи и минимален набор от метрики

Оценяваме агента върху реални задачи, не само върху единични отговори.

Минимален набор:

- процент успешно завършени задачи;
- брой стъпки до успех;
- честота на грешен инструмент или грешни параметри;
- цена и време;
- случаи, в които правилно пита човек;
- случаи, в които трябва да спре, но не спира.

Винаги сравняваме с проста базова линия.

↓ Тетрадка

Цялостен агент с инструменти, памет, планиране и диагностика

Принцип на най-малките права и ограничители

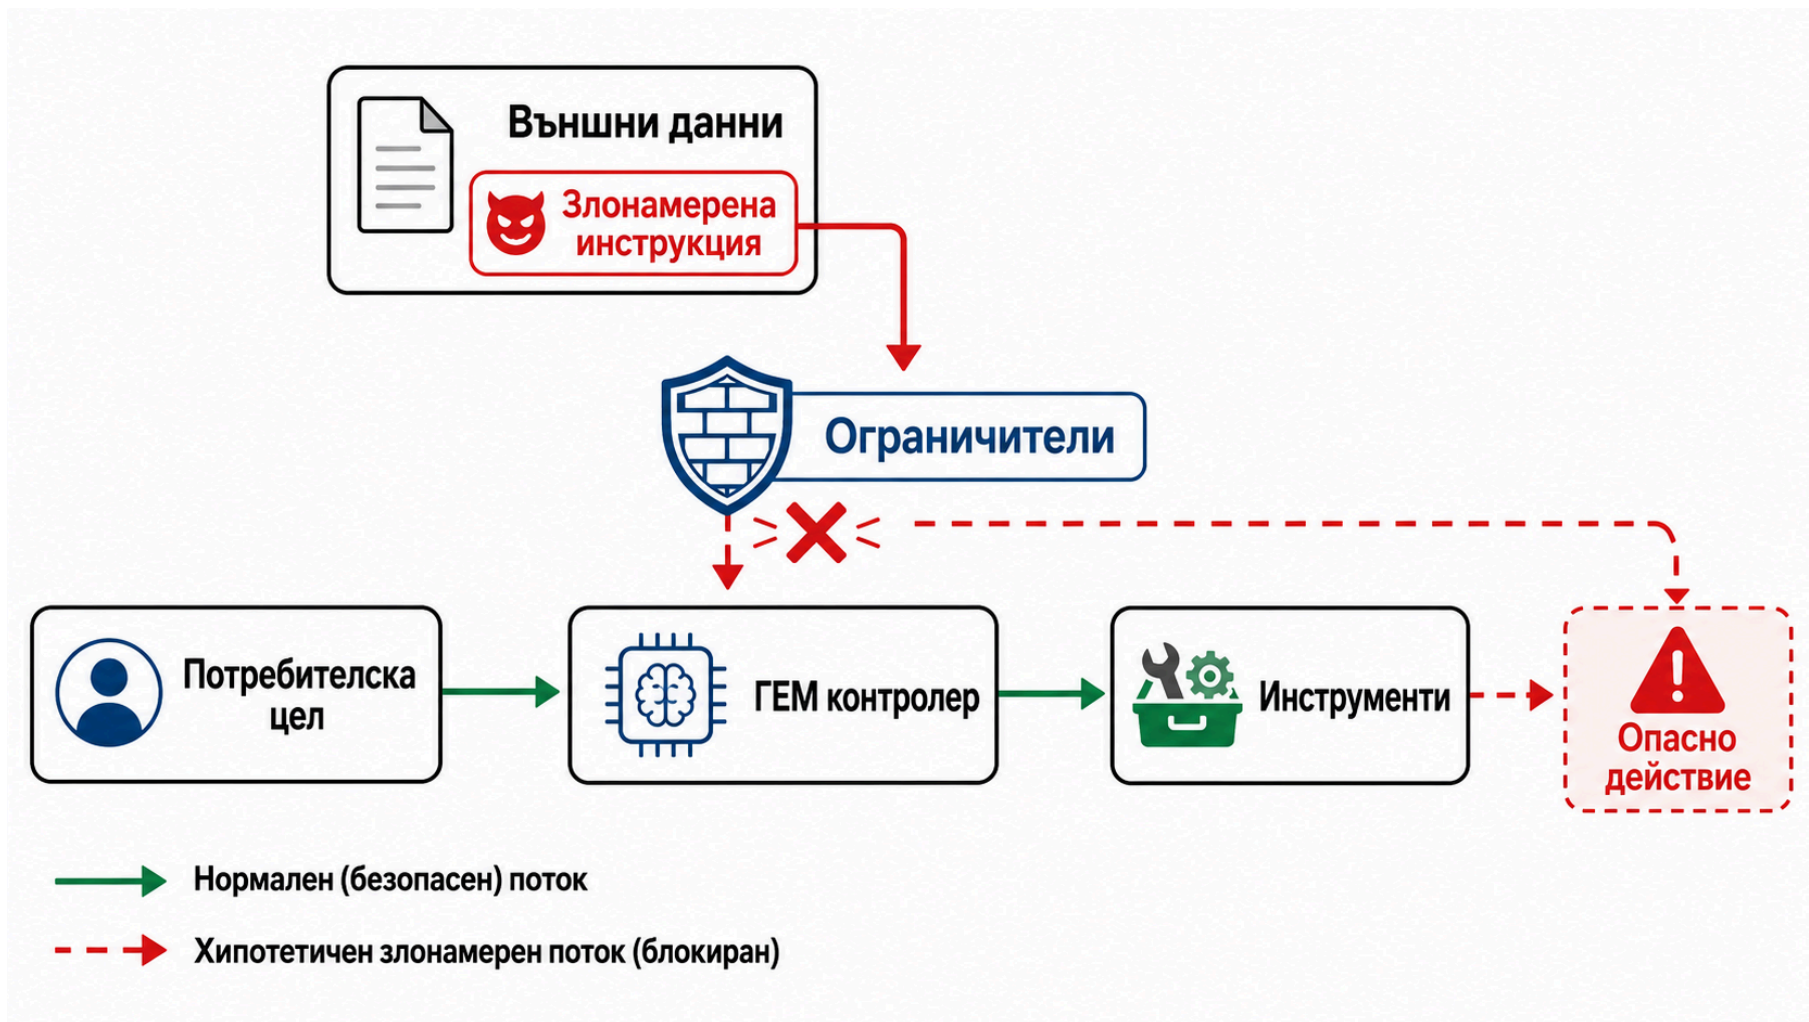
Агентът трябва да получава само правата, които са нужни за задачата.

Ограничители:

- списък с позволени инструменти;
- забранени действия;
- лимит на стъпки, време и цена;
- изолирана среда за изпълнение;
- валидация на параметри;
- потвърждение преди чувствителни или необратими действия.

По-малко права означава по-малък радиус на щетите при грешка.

Риск: инжектиране на подкани



↓ Тетрадка

Инжектиране на подкани през резултат от инструмент

Обобщение

- Агентът е система с цел, среда, действия, наблюдения и обратна връзка.
- ГЕМ най-често е контролер, а не самостоятелен изпълнител на всичко.
- Инструментите дават възможност за действие, но изискват ясни схеми и валидация.
- Паметта и планирането помагат при дълги задачи, но добавят нови рискове.
- Надеждността идва от оценяване по задачи, следи на изпълнение и ясни критерии за спиране.
- Безопасността изисква най-малки права, разделяне на инструкции от данни и човек в цикъла.